

스마트교통 빅데이터 분석

VDS 데이터 분석 및 기계학습 적용 실습하기





교통 데이터 다운로드

국가교통데이터 오픈마켓

대전시 VDS 운행 원시 이력 데이터

- VDS(Vehicle Detection System): 차량검지기
 - ✓ 도로 상에 약 1km 간격으로 설치되어 실시간으로 교통량, 점유율, 속도, 대기행렬길이, 차량길이 등의 정보를 검지하여 소통 및 돌발상황 등을 감시하는 장치로 도로 환경적 특성에 따라 설치하며 종류는 루프식, 영상식, 레이더식 등이 있다
 - ✔ 대전시 VDS 운행 원시 이력 데이터 (등록일자, 검지기 ID, VDS ID, VDS 구간 ID, 요일 구분, 교통량 (소/중/대형), 속도, 점유율, 차두 길이, 차두 시간 등)









대전시 VDS 운행 원시 이력 데이터

대전시 VDS 운행 원시 이력 데이터 [vds-collect-info.zip] 외 5건(80.74MB)

결제금액 합계:0원

결제완료

상품 다운로드 ⊥

문의하기



교통 데이터 다운로드

http://tportal.daejeon.go.kr/stats/content01.view?search=1 교통데이터 DW 시스템 (대전시)



판다스 연습

KISTH이터 오브젝트 생성하기



Series

- ✓ Series는 같이 값들의 리스트를 넘겨주어 만듬
- ✔ 인덱스는 자동적으로 기본적으로 지정되는 정수 인덱스를 사용
- 1차원 배열 같은 구조 (예)
 - ✓엑셀로 보면 복수의 행(row)으로 이루어진 1개의 열,
 - ✓복수의 열(column)으로 이루어진 하나 행(row)의 값
 - ✓엑셀처럼, column들이 색인(index)을 가지고 있어 데이터를 지칭하는 이름을 가짐

```
df = pd.DataFrame(np.random.randn(8,5), index=dates, columns=list('abcde'))
```

df

	а	b	С	d	е
2020-01-01	-0.802490	-0.670454	0.571352	-1.001153	0.205154
2020-01-02	-0.802341	0.329855	1.889353	-1.574091	-0.259556
2020-01-03	0.272315	-0.678223	-0.328725	-0.066139	0.158881
2020-01-04	-1.103216	-0.831071	2.872117	1.987097	-1.521131
2020-01-05	0.218559	0.072759	0.531204	0.785738	-0.294122
2020-01-06	-1.433724	0.648570	-0.498555	-1.563853	-0.988152
2020-01-07	-0.867036	-1.141157	0.638432	1.491141	-0.433551
2020-01-08	2.700744	-1.400121	1.222277	-0.602262	0.200138

DataFrame 만들기 다른 방법

In [31]: df2

Out [31]:

	а	b	С	d	е	f
0	1.0	2013-01-02	1.0	3	test	foo
1	1.0	2013-01-02	1.0	3	train	foo
2	1.0	2013-01-02	1.0	3	test	foo
3	1.0	2013-01-02	1.0	3	train	foo



head(), head(5) 위에서 부터 데이터 보여줌

df.head()

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801

df.head(3)

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681

df.tail()

	а	b	С	d	е
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

df.tail(3)

	а	b	С	d	е
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

DataFrame 속성 확인

DataFrame 속성 확인 index, columns, values

```
df.index
DatetimeIndex(['2020-01-01', '2020-01-02', '2020-01-03', '2020-01-04',
               '2020-01-05'. '2020-01-06'. '2020-01-07'. '2020-01-08'].
              dtype='datetime64[ns]', freq='D')
df.columns
Index(['a', 'b', 'c', 'd', 'e'], dtype='object')
df.values
array([[-0.1617311 . 0.84452809 . -0.43382289 . 0.38187277 . 1.10848399].
       [0.97981521, -0.08804282, -0.22897753, -1.39795857, -1.39874591],
       [1.27615329, -1.47740467, 0.9570735, -0.5431942, -0.39568057],
       [ 0.00644179, 1.63848983, 0.73020528, 0.51741274, -1.09175269],
       [-1.10150497, -0.89583825, -0.27186124, -0.13472203, 0.17980079],
       [ 2.21416968, -1.31659282, -1.89851741, -1.265935 , -1.57235185],
       [-0.6060803 . -2.32160025 . 0.18614666 . -0.53517175 . 1.63562266]
       [ 0.13848857, -1.13541823, 0.62121683, 1.36880715, -2.36526483]])
```



df.describe()

	а	b	С	d	е
count	8.000000	8.000000	8.000000	8.000000	8.000000
mean	0.343219	-0.593985	-0.042317	-0.201111	-0.487486
std	1.080660	1.308257	0.908243	0.935041	1.383935
min	-1.101505	-2.321600	-1.898517	-1.397959	-2.365265
25%	-0.272818	-1.356796	-0.312352	-0.723879	-1.442147
50%	0.072465	-1.015628	-0.021415	-0.334947	-0.743717
75%	1.053900	0.145100	0.648464	0.415758	0.411972
max	2.214170	1.638490	0.957074	1.368807	1.635623

컬럼별로 데이터의 개수(count), 데이터의 평균 값(mean), 표준 편차(std), 최솟값(min), 4분위수(25%, 50%, 75%), 그리고 최댓값(max)들의 정보

정렬 메소트 .sort_index()

df.sort_index(axis=0, ascending=True)

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

df.sort_index(axis=1, ascending=True)

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

정렬 할 대상 축을 결정할때에는 axis를 이용하며, axis=0는 인덱스 기준으로 정렬(기본값), axis=1은 칼럼 기준으로 정렬함 정렬의 방향은 ascending을 이용하며, ascending=True는 오름차순 정렬(기본값); ascending=False는 내림차순 정렬 df

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

df['a']

-0.161731 2020-01-01 2020-01-02 0.979815 2020-01-03 1.276153 0.006442 2020-01-04 2020-01-05 -1.101505 2020-01-06 2.214170 2020-01-07 -0.606080 2020-01-08 0.138489 Freq: D, Name: a, dtype: float64 df[0:4]

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753

df['2020-01-02':'2020-01-06']

	а	b	С	d	е
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352

데이터프레임 자체가 갖고 있는 슬라이싱은 df[컬럼명], df[시작인덱스:끝인덱스+1], df[시작인덱스명:끝인덱스명]의 형태로 사용

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

.iloc는 위치를 이용하여 선택하기

df

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265

df.iloc[3]

- a 0.006442
- b 1.638490
- c 0.730205
- d 0.517413
- e -1.091753

Name: 2020-01-04 00:00:00, dtype: float64

다음과 같이 위치를 나타내는 인덱스 번호를 이용하여 데이터를 선택

여기서 인덱스 번호는 python에서 사용하는 인덱스와 같은 개념

인덱스 번호는 0 부터 시작하므로, 첫 번째 데이터는 인덱스 번호가 0 이고, 두 번째 데이터는 인덱스 번호가 1 임. 인덱스 번호 3 (네 번째 행)을 선택하는 예제

조건을 이용하여 선택하기

조건을 이용한 선택 ¶

df[df.b > 0]

	а	b	С	d	е
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753

df[df > 0]

	а	D	С	a	е
2020-01-01	NaN	0.844528	NaN	0.381873	1.108484
2020-01-02	0.979815	NaN	NaN	NaN	NaN
2020-01-03	1.276153	NaN	0.957074	NaN	NaN
2020-01-04	0.006442	1.638490	0.730205	0.517413	NaN
2020-01-05	NaN	NaN	NaN	NaN	0.179801
2020-01-06	2.214170	NaN	NaN	NaN	NaN
2020-01-07	NaN	NaN	0.186147	NaN	1.635623
2020-01-08	0.138489	NaN	0.621217	1.368807	NaN

```
df4 = df.copy()
df4['f'] = ['one', 'one', 'two', 'three', 'four', 'three', 'six', 'seven']
```

df4

	а	D	С	a	е	т
2020-01-01	-0.161731	0.844528	-0.433823	0.381873	1.108484	one
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746	one
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681	two
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753	three
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801	four
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352	three
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623	six
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265	seven

df4[df4['f'].isin(['two', 'four'])]

	а	b	С	d	е	f
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681	two
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801	four

데이터 변경하기

데이터 변경하기

	а	b	С	d	е	f
2020-01-01	0.000000	0.844528	-0.433823	0.381873	1.108484	NaN
2020-01-02	0.979815	-0.088043	-0.228978	-1.397959	-1.398746	1.0
2020-01-03	1.276153	-1.477405	0.957074	-0.543194	-0.395681	2.0
2020-01-04	0.006442	1.638490	0.730205	0.517413	-1.091753	3.0
2020-01-05	-1.101505	-0.895838	-0.271861	-0.134722	0.179801	4.0
2020-01-06	2.214170	-1.316593	-1.898517	-1.265935	-1.572352	5.0
2020-01-07	-0.606080	-2.321600	0.186147	-0.535172	1.635623	6.0
2020-01-08	0.138489	-1.135418	0.621217	1.368807	-2.365265	NaN

여기결손데이터(Missing Data) 처리



- 결손데이터(Missing Data)는: 여러가지 이유로데이터를 전부 다 측정하지 못하는 경우가 종종 발생하며, Pandas는 편리한 API를 제공한다. 결손데이터는 컬럼에 값이 없는 NULL을 의미하며, 넘파이의 NaN으로 표시, 즉, np.nan
- pandas는 결손 데이터를 NaN을 처리하지 않으므로 이 값을 다른 값으로 대체해야 함. 또한 NaN 값은 평균, 총합 등의 함수 연사 시 제외 됨.
- NaN 여부를 확인하는 API는 isna()이며, NaN 값을 다른 값으로 대체하는 API는 fillna().
- 재인덱싱은 해당 축에 대하여 인덱스를 변경/추가/삭제를 함.



fillna()로 결손데이터 대체하기

df1.fillna(value=999)

	a	b	С	d	е	f	g
2020-01-01	0.000000	1.737818	0.449463	0.700941	-0.350025	999.0	1.0
2020-01-02	-0.699451	-0.241029	0.591983	-0.625677	-0.141708	1.0	1.0
2020-01-03	-0.863738	1.314997	-1.633504	-1.316650	-1.132148	2.0	999.0
2020-01-04	-1.619386	2.101894	-1.303257	-0.771174	-0.865577	3.0	999.0

df1

	a	b	С	d	е	f	g
2020-01-01	0.000000	1.737818	0.449463	0.700941	-0.350025	NaN	1.0
2020-01-02	-0.699451	-0.241029	0.591983	-0.625677	-0.141708	1.0	1.0
2020-01-03	-0.863738	1.314997	-1.633504	-1.316650	-1.132148	2.0	NaN
2020-01-04	-1.619386	2.101894	-1.303257	-0.771174	-0.865577	3.0	NaN

apply lambda 함수 이용해보기

```
def get_square(a):
    return a**2
print('4의 제곱은:', get_square(4))
4의 제곱은: 16
```

위는 함수의 정의이고, lambda는 보다 쉽게 적용

```
lambda_square = lambda x: x ** 2
print('4의 제곱은:', lambda_square(4))
```

4의 제곱은: 16

df=df[0:3]: df

	a	b	С	d	е	f
2020-01-01	0.000000	1.737818	0.449463	0.700941	-0.350025	NaN
2020-01-02	-0.699451	-0.241029	0.591983	-0.625677	-0.141708	1.0
2020-01-03	-0.863738	1.314997	-1.633504	-1.316650	-1.132148	2.0

df.apply(np.cumsum)

	a	b	С	d	е	f
2020-01-01	0.000000	1.737818	0.449463	0.700941	-0.350025	NaN
2020-01-02	-0.699451	1.496789	1.041446	0.075265	-0.491733	1.0
2020-01-03	-1.563189	2.811785	-0.592058	-1.241385	-1.623881	3.0

판다스는 apply 함수에 lambda 식을 결함해 DataFrame이나 Series의 레코드별로 데이터를 가공 기능 제공

복잡한 데이터 가공의 경우 어쩔 수 없이 apply lambda를 적용한다.

```
df.apply(lambda x: x.max() - x.min())
    0.863738
    1.978847
    2.225487
    2.017591
    0.990441
    1.000000
dtype: float64
df.mean()
   -0.521063
    0.937262
   -0.197353
   -0.413795
  -0.541294
    1.500000
dtype: float64
```





- 같은 형태의 자료를 이어주는 concat
- 다른 형태의 자료를 한 컬럼으로 합치는 merge
- 기존 데이터 프레임에 하나의 행을 추가하는 append

6. 합치기

df = pd.DataFrame(np.random.randn(10, 4))
df

	0	1	2	3
0	-0.962940	-0.104394	-0.074647	1.533884
1	-0.600499	0.213632	-0.040409	0.642713
2	-0.465268	-1.266487	-1.023249	1.022946
3	-0.286531	2.373228	-0.775739	0.583997
4	0.361653	0.225475	-1.397136	-0.346902
5	-2.350007	-0.667676	-0.299217	0.278333
6	1.799277	0.516733	1.873353	1.150520
7	-0.407686	0.463574	-1.591343	0.109620
8	1.188445	0.644770	0.427377	-0.325065
9	1.067360	1.295874	1.302318	-0.602613

pd.concat(pieces)

0 -0.962940 -0.104394 -0.074647 1.533884 1 -0.600499 0.213632 -0.040409 0.642713 2 -0.465268 -1.266487 -1.023249 1.022946 3 -0.286531 2.373228 -0.775739 0.583993
2 -0.465268 -1.266487 -1.023249 1.022946
1.020210 1.022210
3 -0.286531 2.373228 -0.775739 0.583997
0.20001 2.070220 0.770700 0.000000
4 0.361653 0.225475 -1.397136 -0.346902
5 -2.350007 -0.667676 -0.299217 0.278333
6 1.799277 0.516733 1.873353 1.150520
7 -0.407686 0.463574 -1.591343 0.109620
8 1.188445 0.644770 0.427377 -0.325065
9 1.067360 1.295874 1.302318 -0.602613

18:Time Series 데이터 처리



- 시계열 데이터에서 1초 마다 측정된 데이터를 5분 마다 데이터의 형태 변환가능
 - ✓ 주기(frequency)를 다시 샘플링 할 수 있는 단순하고, 강력하며, 효과적인 기능
 - ✔ 응용으로 금융, 교통, 기상 데이터를 다룰 때 매우 흔히 하는 연산

판타소에서 파일 다루기



- 다양한 포멧을 파일을 DataFrame로 로딩하는 API제공
 - ✓ 대표적으로 read_csv(), read_table(), read_fwf()
- CSV는 컬럼을 ,로 구분이고 read_table은 '₩t' 탭으로 구분됨
 - ✓ 예제, file name은 titanic.csv 파일이 있다면,
 - 판다스에서, df=pd.read_csv(r'C:\Users\hsyi\work\titanic.csv')
 - df.head(4)로 확인함



VDS 데이터 머신러닝

차량검지기 VDS 데이터 분석

plot_ml_curve 라이브러리 설정하기

```
import numpy as np
def plot_ml_curve(estimator, title, X, y, ylim=None, cv=None,
                        n_jobs=None, train_sizes=np.linspace(.1, 1.0, 20)):
   plt.figure()
   plt.title(title)
   if ylim is not None:
        plt.ylim(*ylim)
   plt.xlabel("Training examples")
   plt.ylabel("Score")
   train_sizes, train_scores, test_scores = learning_curve(
        estimator, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
   train_scores_mean = np.mean(train_scores, axis=1)
   train_scores_std = np.std(train_scores, axis=1)
   test_scores_mean = np.mean(test_scores, axis=1)
   test_scores_std = np.std(test_scores, axis=1)
    plt.grid()
    plt.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train scores mean + train scores std, alpha=0.1, color="r")
    plt.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="g")
    plt.plot(train_sizes, train_scores_mean, 'o-', color="r", label="Training score")
   plt.plot(train_sizes, test_scores_mean, 'o-', color="g", label="Cross-validation score")
    plt.legend(loc='lower right')
   return plt
```

```
[10] import pandas as pd
[11] from pandas import datetime
[12] def parser(x):
         return datetime.strptime(x, '%Y-%m-%d %H:%M')
[13] df = pd.read_csv('./daejeon_vds16.csv', date_parser=parser)
[14] df.head()
```

	Date	ToVol	SmVol	MeVol	LaVol	Speed	Occ.Rate
0	2017-04-02 0:00	43	34	9	0	50.3	1.90
1	2017-04-02 0:05	45	32	13	0	58.9	1.84
2	2017-04-02 0:10	46	34	12	0	50.6	1.87
3	2017-04-02 0:15	45	36	9	0	50.9	1.72
4	2017-04-02 0:20	27	13	13	1	62.2	1.12

df.info()

cclass 'pandas.core.frame.DataFrame'>
RangeIndex: 8064 entries, 0 to 8063
Data columns (total 7 columns):

```
Column
             Non-Null Count Dtype
             8064 non-null object
    Date
    ToVol
             8064 non-null
                            int64
    SmVol
             8064 non-null
                            int64
    MeVol
          8064 non-null
                            int64
    LaVol
             8064 non-null
                            int64
    Speed
             8064 non-null float64
    Occ.Rate 8064 non-null float64
dtypes: float64(2), int64(4), object(1)
memory usage: 441.1+ KB
```



	ToVol	SmVol	MeVol	LaVol	Speed	Occ.Rate
count	8064.000000	8064.000000	8064.000000	8064.000000	8064.000000	8064.000000
mean	110.459945	79.353299	29.948537	1.158110	49.327431	6.166941
std	63.954451	46.802106	19.081136	1.530192	7.921856	6.739946
min	6.000000	2.000000	0.000000	0.000000	9.100000	0.230000
25%	50.000000	35.000000	13.000000	0.000000	44.900000	2.140000
50%	122.000000	87.000000	29.000000	1.000000	48.500000	5.550000
75%	155.000000	111.000000	44.000000	2.000000	54.200000	7.290000
max	338.000000	250.000000	145.000000	16.000000	87.800000	82.100000





maxs = df.max()
print(maxs)

Date 2017-04-29 9:55
ToVol 338
SmVol 250
MeVol 145
LaVol 16
Speed 87.8
Occ.Rate 82.1
dtype: object

속도 Speed를 라벨로 정하자

```
def get_score(v):
    if v < 20:
        score = 'Jam'
    elif v < 40:
        score = 'Slow'
    else :
        score = 'Normal'
    return score</pre>
```

```
[20] df["label"] = df["Speed"].apply(lambda v: get_score(v))
    df
```

	Date	ToVol	SmVol	MeVol	LaVol	Speed	Occ.Rate	label
0	2017-04-02 0:00	43	34	9	0	50.3	1.90	Normal
1	2017-04-02 0:05	45	32	13	0	58.9	1.84	Normal




df.head()

	Date	ToVol	SmVol	MeVol	LaVol	Speed	Occ.Rate	label
0	2017-04-02 0:00	43	34	9	0	50.3	1.90	Normal
1	2017-04-02 0:05	45	32	13	0	58.9	1.84	Normal
2	2017-04-02 0:10	46	34	12	0	50.6	1.87	Normal
3	2017-04-02 0:15	45	36	9	0	50.9	1.72	Normal
4	2017-04-02 0:20	27	13	13	1	62.2	1.12	Normal


3. 데이터 가시화

```
import matplotlib.pyplot as plt
import seaborn as sns
plt.style.use("classic")
```

```
import seaborn as sns
plt.figure(figsize=(14,8))
sns.scatterplot(data=df, x = 'Date', y = 'Speed', hue='label', style='label')
```













кі≶ті ਏਤਕੁਖ਼ਾਹਣਿਲਏ ਰੇਟਿਸ਼ de linewidth = 1.2)












sns.heatmap(df.corr(),annot=True,cmap='YlGnBu')





 $y = df[target_col]$

1) 입력 X와 출력 y의 값을 정하기

```
df['label'].unique()

2]: array(['Normal', 'Slow', 'Jam'], dtype=object)

#feature_cols = ['ToVol', 'SmVol', 'Speed', 'Occ.Rate']
#feature_cols = ['ToVol', 'SmVol', 'LaVol', 'MeVol']
feature_cols = ['ToVol','Occ.Rate']
target_col = 'label'
X = df[feature_cols]
```

X.head()

	ToVol	Occ.Rate
0	43	1.90
1	45	1.84
2	46	1.87
3	45	1.72
4	27	1.12

y.head()

3]: 0 Normal

1 Normal

2 Normal

3 Normal

4 Normal

Name: label, dtype: object

2) 출력용 라벨을 머신러닝

텍스트를 숫자로 바꾸자



3) 데이터를 훈련과 테스트로 나누자

- (실전) 데이터를 validation을 포함해서 나눌수 있다.
- (해보기) 전체 데이터를 train : validation : test = 0.6: 0.2: 0.2 로 나누어라

from sklearn.model_selection **import** train_test_split, ShuffleSplit, learning_curve #from sklearn.model_selection import learning_curve, train_test_split, KFold, ShuffleSplit

X_train, X_test, y_train, y_test = train_test_split(X, y_ohc, test_size=0.20, random_state=30)

```
print(X_train.shape, y_train.shape)
print(X_test.shape, y_test.shape)
```

(6451, 2) (6451,) (1613, 2) (1613,)


```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
```

```
X_{train} = scaler.fit_{transform}(X_{train})
```


 $X_{test} = scaler.transform(X_{test})$


5. sklearn을 이용하여 머신러닝 모델을 만들자

from sklearn.ensemble import RandomForestClassifier from sklearn.tree import DecisionTreeClassifier from sklearn import svm from sklearn.neighbors import KNeighborsClassifier




$$cost(W) = -\frac{1}{n} \sum_{i=1}^{n} [y^{(i)}log(p^{(i)}) + (1 - y^{(i)})log(1 - p^{(i)})]$$






$$\sigma(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$


sklearn learning curve : Regression에서 R2 스코어 사용






$$R^{2} = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_{i} (y_{i} - \hat{y}_{i})^{2}}{\sum_{i} (y_{i} - \overline{y})^{2}}$$








R2가 0에 가까운 경우

1) 로지스틱 회귀

```
from sklearn.linear_model import LogisticRegression
      from sklearn import metrics
ln [42]: m_{r} = LogisticRegression()
       m_lr.fit(X_train,y_train)
Out [42]: LogisticRegression()
ln [43]: pred = m_lr.predict(X_test)
       acc_lr = metrics.accuracy_score(pred,y_test)
       print('The accuracy of the Logistic Regression is', acc_lr)
          The accuracy of the Logistic Regression is 0.9603223806571606
      title = "Learning Curves (Logistic Regression)"
       cv = ShuffleSplit(n_splits=4, test_size=0.2, random_state=0)
```

#import myUtil as myutil
plot_ml_curve(m_lr, title, X, y, ylim=(0.6, 1.01), cv=cv)



2) Support Vector Machine (SVM)

```
sv = svm.SVC()
sv.fit(X_train,y_train)
pred = sv.predict(X_test)
acc_svm = metrics.accuracy_score(pred,y_test)
print('The accuracy of the SVM is:', acc_svm)
```

The accuracy of the SVM is: 0.9671419714817111


```
%%time

title = "SVM Classification"

cv = ShuffleSplit(n_splits=4, test_size=0.2, random_state=0)

plot_ml_curve(sv, title, X, y, ylim=(0.6, 1.01), cv=cv)
```

Wall time: 34.6 s



3) K-Nearest Neighbours


```
knc = KNeighborsClassifier(n_neighbors=6)
knc.fit(X_train,y_train)
pred = knc.predict(X_test)
acc_knn = metrics.accuracy_score(pred,y_test)
print('The accuracy of the KNN is', acc_knn)
```

The accuracy of the KNN is 0.9671419714817111

```
title = "K-Nearest Neighbours (KNN)"


cv = ShuffleSplit(n_splits=4, test_size=0.2, random_state=0)

plot_ml_curve(knc, title, X, y, ylim=(0.6, 1.01), cv=cv, n_jobs=4)
```





```
a_{index} = list(range(1,11))
a = pd.Series()
x = [1,2,3,4,5,6,7,8,9,10]
for i in list(range(1,11)):
   kcs = KNeighborsClassifier(n_neighbors=i)
   kcs.fit(X_train,y_train)
   y_pred = kcs.predict(X_test)
   a=a.append(pd.Series(
      metrics.accuracy_score(y_pred,y_test)))
plt.plot(a_index, a)
plt.xticks(x)
```



4) 램덤포레스트 (RandomForestClassifier)

```
m_rf = RandomForestClassifier(n_estimators=100, max_depth = 3)
```

m_rf.fit(X_train, y_train)


 $pred = m_rf.predict(X_test)$

acc_rf = metrics.accuracy_score(pred,y_test)
print('The accuracy of the RFC is:', acc_rf)

title = "Random Forest Classifier"

cv = ShuffleSplit(n_splits=4, test_size=0.2, random_state=0)

plot_ml_curve(m_rf, title, X, y, ylim=(0.6, 1.01), cv=cv)



5) 의사결정나무 (DecisionTreeClassifier)

```
m_tree = DecisionTreeClassifier()
```

m_tree.fit(X_train, y_train)


prd = m_tree.predict(X_test)

acc_dt = metrics.accuracy_score(pred,y_test)
print('The accuracy of the Decision Tree is:', acc_dt)

title = "Decision Tree Classifier"

cv = ShuffleSplit(n_splits=4, test_size=0.2, random_state=0)

plot_ml_curve(m_tree, title, X, y, ylim=(0.6, 1.01), cv=cv)



	Model	Score
1	Support Vector Machines	0.967142
3	K-Nearest Neighbours	0.967142
0	Logistic Regression	0.960322
2	RandomForest	0.960322
4	Decision Tree	0.001860

